

Filière Licence Sciences pour l'Ingénieur en Informatique - Université de Corse



Rapport Final sur la Réalisation d'un compilateur

Ce projet a pour objectif la création progressive d'un interpréteur dédié au langage d'assemblage. Chaque étape du processus de développement a apporté des améliorations significatives, dotant l'interpréteur de nouvelles capacités d'analyse, d'interprétation, et d'exécution des programmes. Le résultat final est un interpréteur fonctionnel capable de traiter des programmes écrits en langage d'assemblage, avec des perspectives d'optimisation et d'extension pour les étapes à venir.

Encadré par le professeur : SANTUCCI, JEAN-FRANÇOIS.

Réalisé par : Mohamed Amine Boussoualef

Année scolaire 2023-2024

Introduction

Le developpement de l'interpreteur en langage d'assemblage a suivi plusieurs etapes cruciales, visant a construire un interpreteur robuste et fonctionnel. Chaque etape a apporte des ameliorations specifiques, renforçant la capacite de l'interpreteur a analyser, interpreter et executer des programmes ecrits dans ce langage.

Plan :

Étape 1 : Analyse Lexicale

L'analyse lexicale a ete la premiere etape du processus, consistant a decouper le code source en unites lexicales. Les tokens tels que "program," "var," et "const" ont ete identifies, marquant le debut de la construction de la structure syntaxique du programme.

Étape 2 : Analyse Syntaxique

L'etape suivante a introduit l'analyse syntaxique, visant a definir la structure grammaticale du langage d'assemblage. Les regles syntaxiques ont ete etablies, permettant la reconnaissance de la hierarchie des elements du programme.

Étape 3 : Analyse Sémantique et Gestion des Erreurs

L'analyse semantique a ete integree pour gerer la signification des identificateurs dans le programme. La creation d'une table des symboles a facilite le suivi des informations associees a chaque identificateur. La gestion des erreurs a ete renforcee, fournissant des messages d'erreur informatifs en cas de declarations incorrectes.

Étape 4 : Génération de Code P-Code

L'etape 4 a marque une avancee significative avec la generation de code P-Code. Cette transformation a permis de traduire les structures syntaxiques en instructions executables. Les procedures ont ete etendues pour inclure la generation de code pour les expressions, les conditions, les affectations, les entrees/sorties, et les structures de controle.

Tests

Conclusion

Étape 1 : Analyse Lexicale

Introduction :

Ce programme represente un interpreteur conçu pour executer des programmes ecrits dans un langage d'assemblage simple. Chaque etape du programme, telle que la premiere, contribue a l'implementation complete de cette machine virtuelle d'assemblage.

Allocation de Mémoire et Interaction Utilisateur

La premiere etape du programme joue un ro^{le} crucial dans la preparation de la memoire et l'interaction avec l'utilisateur. L'utilisation des mnemoniques d'instructions, les codes operationnels definis par le langage d'assemblage, guide le comportement de l'interpreteur. Cette premiere sequence d'instructions demontre comment le programme alloue de l'espace memoire, sollicite l'entree utilisateur, effectue des operations arithmetiques simples, et prend des decisions conditionnelles.

Plus specifiquement :

L'instruction "INT" alloue deux emplacements memoire supplementaires pour le stockage des donnees.

Les instructions "LDA" et "LDV" manipulent les adresses et les valeurs dans la memoire.

L'instruction "INN" permet a l'utilisateur d'entrer une valeur, laquelle est stockee a une adresse specifiee dans la memoire.

Des operations arithmetiques telles que "ADD" sont effectuees, resultant en des modifications de la memoire.

L'instruction "BZE" introduit une decision conditionnelle, sautant a une adresse specifiee si une condition est remplit.

Explication détaillé du code :

MNEMONIQUES : Cette liste regroupe les mnemoniques des instructions, definissant ainsi les codes operationnels que le programme peut executer. Chaque mnemonique correspond a une instruction specifique, comme l'addition (ADD), la soustraction (SUB), la multiplication (MUL), la division (DIV), etc.

interpreteur(PCODE) : La fonction principale, "interpreteur," accepte en parametre un programme en langage d'assemblage, represente sous forme d'une liste de tuples. Chaque tuple contient une instruction et son operande associe. L'interpreteur parcourt ces instructions pour executer le programme.

MEM (Mémoire) : Utilisée comme une pile, la mémoire (MEM) stocke les données et les résultats intermédiaires du programme. Les opérations s'effectuent en manipulant les éléments de cette pile.

SP (Stack Pointer - Pointeur de pile) : SP indique le sommet de la pile dans la mémoire, facilitant l'ajout et la suppression d'éléments.

PC (Program Counter - Compteur d'instructions) : PC pointe vers l'instruction en cours d'exécution dans le programme. Son rôle est de suivre l'avancement du programme.

PS (Program Status - État du programme) : Initialement défini sur "EXECUTION," PS représente l'état actuel du programme. Lorsque PS atteint "END," l'exécution prend fin.

INST (Instruction) : INST stocke le mnémonique de l'instruction en cours d'exécution, guidant le programme sur la nature de l'opération à effectuer.

OPERANDE : Chaque instruction est associée à un opérande qui détermine son comportement spécifique. Par exemple, l'instruction "INT" alloue de la mémoire en fonction de cet opérande.

Le cœur du programme réside dans une boucle principale (while PS != "END") où chaque itération traite une instruction. Les instructions sont implémentées à l'intérieur de la structure conditionnelle (if-elif-else) en fonction de leur mnémonique.

Par exemple, pour l'instruction "ADD," le programme réalise une addition en manipulant les éléments du sommet de la pile. Des opérations similaires sont effectuées pour les mnémoniques "SUB," "MUL," et "DIV."

L'instruction "INN" sollicite l'interaction de l'utilisateur pour fournir une valeur, laquelle est ensuite stockée à une adresse spécifiée dans la mémoire. À l'inverse, l'instruction "PRN" imprime la valeur du sommet de la pile.

Enfin, l'instruction "HLT" met un terme à l'exécution du programme."

Cette première séquence crée un aperçu détaillé des opérations fondamentales et de l'interaction avec l'utilisateur au sein de la machine virtuelle d'assemblage. Ces opérations élémentaires seront ensuite exploitées et étendues dans les étapes ultérieures du programme pour accomplir des tâches plus complexes.

Conclusion de l'Étape 1 : Fondations de l'Interpréteur

Cette première séquence, axée sur l'allocation de mémoire et l'interaction utilisateur, constitue les fondations essentielles de notre interpréteur de langage d'assemblage. En démontrant comment le programme alloue et manipule la mémoire, sollicite l'entrée utilisateur, et effectue des opérations de base, cette étape crée une infrastructure robuste pour les étapes ultérieures. Ces opérations élémentaires, combinées aux mnémoniques et à la logique de contrôle du programme, posent les bases sur lesquelles des fonctionnalités plus complexes seront édifiées. L'analyse détaillée de cette étape permet de mieux comprendre le fonctionnement interne de notre machine virtuelle d'assemblage, pavant la voie à l'accomplissement de tâches plus avancées dans les prochaines phases du programme.

Étape 2 : Analyse Syntaxique

Introduction

L'analyse syntaxique, visant à définir la structure grammaticale du langage d'assemblage. Les règles syntaxiques ont été établies, permettant la reconnaissance de la hiérarchie des éléments du programme

Traitement des Instructions

Le traitement des instructions a été optimisé pour garantir une séparation adéquate entre les différents éléments du code source. Les caractères spéciaux tels que ";", ",", et "\n" sont correctement gérés, ce qui simplifie la structure du code avant l'analyse. Cela améliore la lisibilité du code et facilite l'identification des éléments clés.

```
if lettre == ";":
    code += " ; "
elif lettre == ",":
    code += " , "
elif lettre == "\n":
    code += " "
else:
    code += lettre
```

Gestion des Blocs

L'analyseur lexical identifie maintenant de manière robuste les blocs "begin" et "end" ainsi que les déclarations de constantes et de variables à l'intérieur de ces blocs. Cette gestion précise des blocs contribue à une meilleure compréhension de la structure du code, facilitant ainsi les étapes ultérieures de l'interprétation.

```
assert ['begin'] in instructions, "SyntaxError: BEGIN expected"
```

Traitement des Erreurs

```
assert re.match("[a-zA-Z_][a-zA-Z_0-9]*", nom_const), f"SyntaxError: \"{nom_const}\"
```

```
is not a legal const name"
```

Des assertions ont été intégrées pour détecter les erreurs potentielles de syntaxe de l'analyse lexicale. Par exemple, des vérifications sont effectuées pour s'assurer que la déclaration de constante est correcte, que les noms de variables sont valides, et que le bloc principal se termine par "end". Ces assertions renforcent la fiabilité du processus d'analyse.

Intégration avec le Code Principal

Encapsulation dans une Fonction

Le code de l'analyseur lexical a été encapsulé dans une fonction appelée `analyseur_lexical`, prenant un fichier en paramètre. Cette modularité facilite l'utilisation de l'analyseur lexical dans le code principal et favorise une structure plus propre et compréhensible.

```
def analyseur_lexical(fichier:str):  
    # ...  
    return instructions
```

Interaction entre les Deux Analyseurs Lexicaux

Une première version d'intégration a été réalisée entre les analyseurs lexicaux du code principal et de l'aide. L'analyseur lexical de l'aide génère des listes de déclarations de constantes et de variables, et l'objectif est d'harmoniser ces listes avec celles générées par le code principal. Cette interaction pose les bases d'une approche unifiée pour traiter le langage d'assemblage.

Conclusion de l'Étape 2

L'Étape 2 représente une étape cruciale dans l'amélioration de la robustesse de l'analyseur lexical. Les améliorations apportées permettent une gestion plus précise du code source, tandis que l'intégration entre les deux analyseurs lexicaux renforce la cohérence du projet. Ces ajustements jetteront les bases d'une implémentation solide pour les étapes suivantes du développement. L'attention portée aux détails et la gestion proactive des erreurs sont des éléments clés de cette avancée.

Étape 3 :

Analyse Sémantique et Gestion des Erreurs

Introduction

L'Étape 3 du développement de l'interpréteur de langage d'assemblage marque une avancée majeure dans l'amélioration de la robustesse de l'interpréteur. Les principales fonctionnalités ajoutées comprennent l'analyse sémantique, la gestion des erreurs, et la création d'une table des symboles. Ces améliorations sont cruciales pour garantir une interprétation correcte des programmes.

Analyse Sémantique

L'analyse sémantique constitue une étape clé dans le traitement des programmes. Elle se concentre sur la gestion de la table des symboles (TABLESYM), qui agit comme une base de données centralisée pour stocker des informations sur chaque identificateur utilisé.

```
# Initialisation de l'offset et de la table des symboles
offset = 0
TABLESYM = []
```

Table des Symboles

La table des symboles est une liste de triplets, stockant le nom, la classe (programme, constante, variable), et l'adresse mémoire de chaque identificateur.

```
# Fonction pour entrer un symbole dans la table des symboles
def entrerSym(classe, value):
    global TABLESYM, offset
    if classe == 'constant':
        value = PROGRAM[i + 1]
    TABLESYM += [(PROGRAM[i - 1], classe, value)]
    offset += 1
```

Gestion des Constantes et Variables

Les fonctions `consts` et `Vars` ont été étendues pour intégrer la création des symboles correspondants dans la table des symboles. Cela garantit une déclaration correcte de chaque identificateur utilisé dans le programme.

Allocation de Mémoire et Gestion des Erreurs

L'allocation de mémoire repose sur un offset, qui s'incrémente à mesure que de nouveaux symboles sont ajoutés. Cette approche assure une utilisation efficace de la mémoire.

```
# Fonction pour chercher un symbole dans la table des symboles
def chercherSym(sym):
    global TABLESYM
    res = False
    for s in TABLESYM:
        if s[0] == sym:
            res = s
    if res:
        return res
    else:
        erreur_dec(sym)
```

Gestion des Erreurs

La gestion des erreurs a été renforcée pour fournir des messages d'erreur détaillés. Par exemple, si un identificateur n'est pas déclaré, un message spécifique est affiché.

Perspectives Futures

L'étape 3 offre une base solide pour l'analyse de programmes plus complexes en langage d'assemblage. Les développements futurs pourraient inclure l'extension des fonctionnalités, l'ajout de structures de contrôle avancées, et des améliorations continues de la gestion des erreurs.

Conclusion

L'étape 3 représente un progrès significatif dans le renforcement de l'interpréteur. Les nouvelles fonctionnalités, en particulier la gestion avancée des identificateurs via la table des symboles, augmentent la qualité de l'analyse sémantique. Ces ajustements préparent le terrain pour des développements futurs plus avancés, consolidant ainsi la capacité de l'interpréteur à traiter des programmes complexes en langage d'assemblage.

Étape 4 :

Génération de Code P-Code

Introduction

L'étape 4 représente une avancée majeure dans le développement de l'interpréteur en se focalisant sur la génération de code P-Code. Cela permet de traduire les structures syntaxiques en instructions exécutables, marquant ainsi une étape cruciale vers l'exécution effective des programmes analysés.

Génération de Code lors de l'Allocation des Données

La première étape consiste à allouer l'espace nécessaire dans la pile P-Code, réalisée par la procédure BLOCK. L'instruction P-Code INC est générée pour réserver cet espace.

```
def block():
    global offset
    if token == "const":
        consts()
    if token == "var":
        Vars()
    generer2('INC', offset)
    insts()
```

MonCode.code X

```
1  program abc ;
2  const C = 10 ; var A,B ; (* Ceci est un commentaire *)
3  begin
4  A := 0 ;
5  B := 0 ;
6  while A <> 0 do
7  begin
8  read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
9  B := A + B ;
10 end ;
11 write ( B ) ; (* affiche le resultat final de B *)
12 end .
```

Terminaison du Programme et Instruction HLT

La procedure PROGRAM genere l'instruction P-Code HLT pour indiquer la fin du programme.

```
def program():
    teste("program")
    test_et_entre(ID, 'program')
    teste(";")
    block()
    generer1('HLT')
    if token != ".":
        erreur(".", token)
```

Génération de Code pour les Expressions

La generation de code pour les expressions est detaillee dans les procedures TERM, FACT, et EXPR. Chaque terme laisse une valeur sur la pile P-Code, et les operations de multiplication et de division sont prises en compte.

```
def term():
    global token
    fact()
    while token in ["*", "/"]:
        op = token
        next_token()
        fact()
        if op == "*":
            generer1('MUL')
        else:
            generer1('DIV')
```

Génération de Code pour les Conditions

La generation de code pour les conditions suit une approche similaire a celle des expressions, en prenant en compte les operations relationnelles.

```
def cond():
    expr()
    if token in ["==", "<>", "<", ">", "<=", ">="]:
        next_token()
        expr()
```

Génération de Code pour les Instructions d'Affectation

La procedure AFFEC genere le code P-Code pour une instruction d'affectation $A := \text{expression}$.

```
def affec():
    global token, PLACESYM
    ADDR = getAdresseFromTableSym(token)
    test_et_cherche(ID)
    generer2('LDA', ADDR)
    teste(":=")
    expr()
    generer1('STO')
```

Génération de Code pour les Instructions d'Entrée/Sortie

Les instructions d'entree/sortie, ECRIRE et LIRE, sont egalement gerees dans la generation de code.

```
def ecrire():
    teste("write")
    teste("(")
    expr()
    generer1('PRN')
    while token == ",":
        next_token()
        expr()
        generer1('PRN')
    teste(")")
```

Procédures de Génération de P-Code pour les Structures de Contrôle

Les procedures de generation de P-Code sont etendues pour traiter les structures de controle IF et WHILE.

```
def si():
    teste("if")
    cond()
    teste("then")
    generer2('BZE', 0)
    inst()
```

Conclusion

L'etape 4 marque une transition essentielle vers la concretisation des programmes analyses. La generation de code P-Code permet de traduire les structures syntaxiques en instructions executables, ouvrant la voie a une interpretation complete des programmes en langage d'assemblage. Les perspectives futures pourraient inclure l'optimisation du code genere et l'ajout de fonctionnalites avancees.

Test

Elever le mot program

```
MonCode.code X etape4.py
1 | abc ;
2 | const C = 10 ; var A,B ; (* Ceci est un commentaire *)
3 | begin
4 |   A := 0 ;
5 |   B := 0 ;
6 |   while A <> 0 do
7 |     begin
8 |       read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
9 |       B := A + B ;
10 |     end ;
11 |     write ( B ) ; (* affiche le resultat final de B *)
12 |   end .
13 |
```

```
File "c:\Users\pc\Desktop\DOSSIER\compilation\projet\mon projet\aide.py", line 117, in <module>
    analyseur_lexical("MonCode.code")
File "c:\Users\pc\Desktop\DOSSIER\compilation\projet\mon projet\aide.py", line 51, in analyseur_lexical
    assert instruction[0] == "program", "SyntaxError: Missing program declaration in header"
```

AssertionError: SyntaxError: Missing program declaration in header

Elever le mot Const avant C

```
1 program abc ;
2 | C = 10 ; var A,B ; (* Ceci est un commentaire *)
3 begin
4   A := 0 ;
5   B := 0 ;
6   while A <> 0 do
7     begin
8       read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
9       B := A + B ;
10    end ;
11    write ( B ) ; (* affiche le resultat final de B *)
12  end .
```

```
on/projet/mon projet/etape4.py"
ERREUR expected: begin given: C
```

Elever le mot var

```
1  program abc ;
2  const C = 10 ;
3  | A,B ; (* Ceci est un commentaire *)
4  begin
5  A := 0 ;
6  B := 0 ;
7  while A <> 0 do
8  begin
9  read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
10 B := A + B ;
11 end ;
12 write ( B ) ; (* affiche le resultat final de B *)
13 end .
14
```

```
File "c:\Users\pc\Desktop\DOSSIER\compilation\projet\mon projet\aide.py", line 108, in analyseur_lexical
    assert element in listVar or element in listConst, f"SyntaxError: '{element}' variable not declared"
    ^^^^^^^
UnboundLocalError: cannot access local variable 'listVar' where it is not associated with a value
```

Elever le ;

```
program abc ;
const C = 10 ;
var A,B (* Ceci est un commentaire *)
begin
A := 0 ;
B := 0 ;
while A <> 0 do
begin
read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
B := A + B ;
end ;
write ( B ) ; (* affiche le resultat final de B *)
end .
```


Utiliser variable non déclarer

```

1  program abc ;
2  const C = 10 ; var B ; (* Ceci est un commentaire *)
3  begin
4  A := 0 ;
5  B := 0 ;
6  while A <> 0 do
7  begin
8  read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
9  B := A + B ;
10 end ;
11 write ( B ) ; (* affiche le resultat final de B *)
12 end .

```

```

analyseur_lexical(NonDefCode)
File "c:\Users\pc\Desktop\DOSSIER\compilation\projet\mon projet\aide.py", line 108, in analyseur_lexical
    assert element in listVar or element in listConst, f"SyntaxError: '{element}' variable not declared"
    ~~~~~
AssertionError: SyntaxError: 'A' variable not declared

```

Test réussi

```
program abc ;
const C = 10 ; var A,B ; (* Ceci est un commentaire *)
begin
A := 0 ;
B := 0 ;
while A <> 0 do
begin
read ( A ) ; (* entrer la valeur de A tant que A different 0 *)
B := A + B ;
end ;
write ( B ) ; (* affiche le resultat final de B *)
end .
```

```
on/projet/mon_projet/etape4.py"
```

$$B = 6$$

Conclusion Final

Le developpement progressif de l'interpreteur a abouti a la creation d'un outil capable d'analyser et d'executer des programmes en langage d'assemblage. Chaque etape a contribue a renforcer la capacite de l'interpreteur, ouvrant la voie a des ameliorations continues et a des developpements futurs. Des perspectives comme l'optimisation du code genere et l'ajout de fonctionnalites avancees pourraient enrichir davantage cet interpreteur.